Semantik Analiz

- Semantik Analiz, bağlamı, cümlelerin mantıksal yapısını ve dilbilgisi kurallarını dikkate alarak verilen metnin anlamını yakalar.
- Doğal Dilin Anlamsal Analizi iki ana başlığa ayrılabilir:

  1. Lexical (Sözcük) Semantik Analizi: Sözcüksel anlam analizi, metindeki her kelimenin anlamını ayrı ayrı anlamayı içerir. Temelde, metindeki bir kelimenin sözlükteki karşılığını bulmayı ifade eder.

  2. Compositional (Kompozisyonel) Semantik Analizi: Metnin her kelimesinin anlamını bilmek esas olsa da, metnin anlamını tamamen anlamak için yeterli değildir.
- Örneğin, aşağıdaki iki cümleyi ele alalım:
  - **Cümle 1:** Öğrenciler okulu çok seviyor.
  - **Cümle 2:** Okul öğrencileri sever.

Semantik Analiz

- Bir cümlenin anlamını kavrayabilmek için, anlamsal analizde yer alan başlıca süreçler şunlardır:
  1. Kelime Anlamı Belirsizliğinin Giderilmesi
  2. İlişki Çıkarma
- Semantik Sistemin Yapı Taşları:
  - **Varlıklar** – Belirli bir kişi, yer vb. gibi bireyi temsil eder. Örneğin; Okul, Türkiye
  - **Kavramlar** – Kişi, şehir vb. gibi bireylerin genel kategorisini temsil eder. Örneğin; Öğrenci, Samsun
  - **İlişkiler** – Varlıklar ve kavramlar arasındaki ilişkiyi temsil eder. Örneğin; Samsun bir şehirdir.
  - **Yüklemler** – Fiil yapılarını temsil eder.

Embedding Modelleri

- Word2Vec
- GloVe
- FastText

Word2Vec

- **Word2Vec,** NLP'de kelimelerin sürekli bir vektör uzayında vektörler olarak temsil edilmesini sağlayan **embedding** tekniğidir.
- Google tarafından geliştirildi.
- Amaç kelimeler arasındaki anlamsal ilişkileri yakalamak.
- Bunun için kelimeler yüksek boyutlu vektörlere dönüştürüldü.
- *Temel modelleri: CBOW ve Skip-Gram*

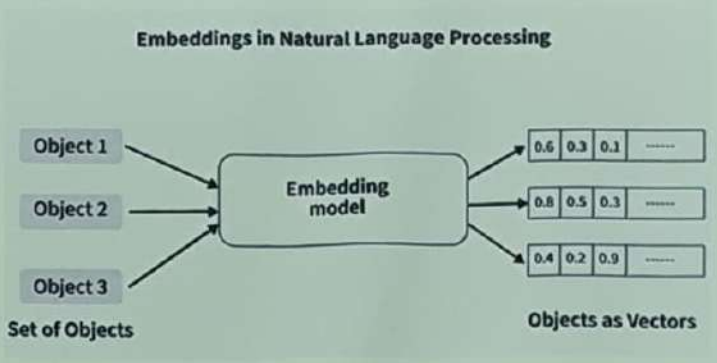

Word Embedding

Cat →	1.2	-0.1	4.3	3.2
Mat →	0.4	2.5	-0.9	0.5
on →	2.1	0.3	0.1	0.4

CBOW (Continuous Bag of Words)

- CBOW modeli, belirli bir pencere içindeki bağlam kelimeleri verildiğinde geçerli kelimeyi tahmin eder.

Bugün _?_ çok güzel

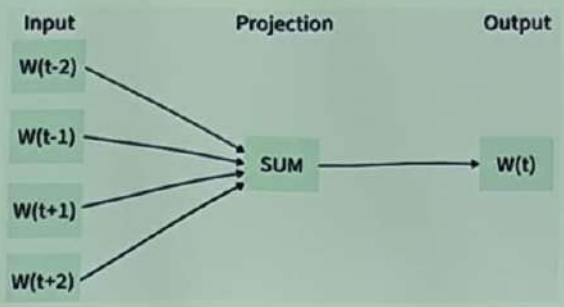

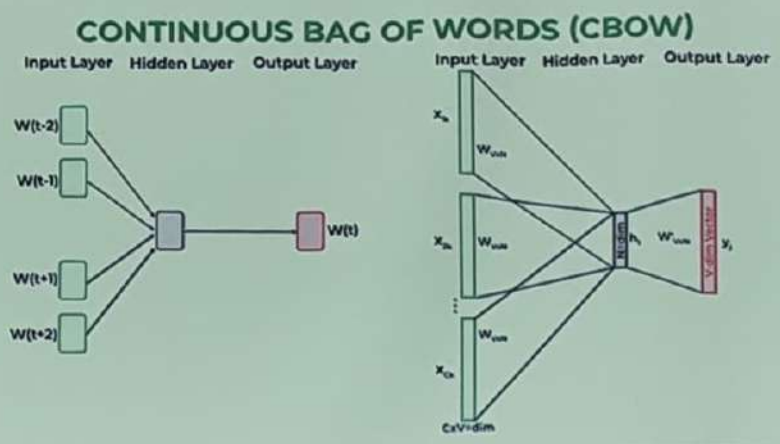

Skip Gram

- Skipgram , verilen kelimeye göre belirli bir pencere içindeki çevreleyen bağlam kelimelerini tahmin eder.

hava → bugün, çok, güzel

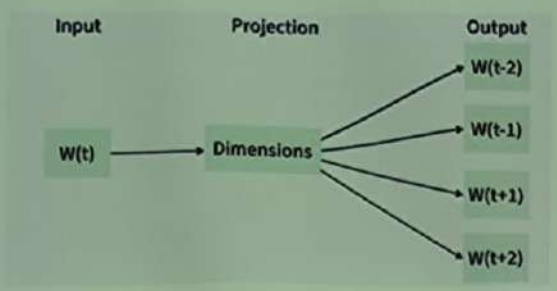

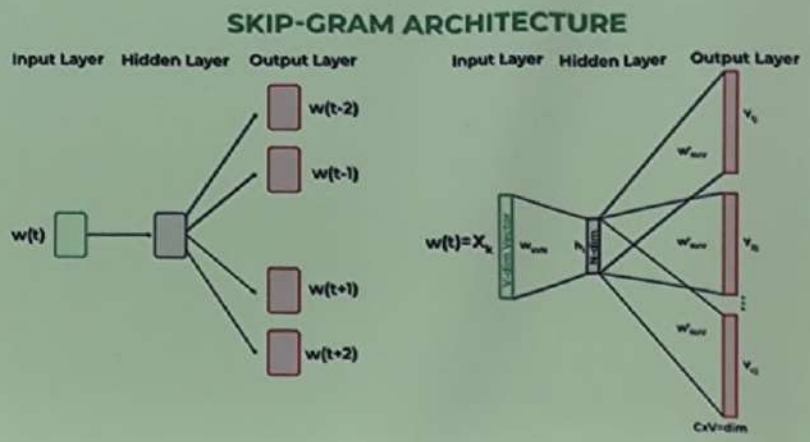

CBOW ve Skip Gram

Example with Window Size 3

Sentence:
["India", "wins", "next", "world", "cup"]

CBOW Training Example

- *Context: ["India", "wins", "next"] → Target: "world"*

Skip-Gram Training Example

- *Target: "India" → Context: ["wins", "next", "world"]*
- *Target: "wins" → Context: ["India", "next", "world"]*
- *Target: "next" → Context: ["wins", "world", "cup"]*

Word2Vec

Özellik	CBOW	Skip-gram
Tahmin yönü	Bağlam → Kelime	Kelime → Bağlam
Eğitim hızı	Daha hızlı (bağlam penceresi başına tek tahmin)	Daha yavaş (hedef kelime başına birden fazla tahmin)
Bağlam penceresi	Genellikle daha kısa (2-5 kelime)	Daha büyük pencereleri (5-20 kelime) işleyebilir.
Performans	Sık kullanılan kelimeler ve sözdizimsel ilişkiler için daha uygundur.	Nadir kelimeler ve anlamsal ilişkiler için daha iyi.
Veri Gereksinimleri	Daha az veriye ihtiyaç duyuyor	Daha fazla veriye ihtiyaç duyuyor, büyük veri kümeleriyle iyi çalışıyor.
Kullanım Senaryoları	Metin sınıflandırma ve duygu analizi gibi ayrıntılı kelime temsillerinden ziyade hız gerektiren görevler için uygundur.	Kelime benzerliği, adlandırılmış varlık tanıma ve makine çevirisi gibi yüksek kaliteli gömme vektörleri ve ayrıntılı anlamsal ilişkiler gerektiren görevler için idealdir.

GloVe

- GloVe (Global Vectors for Word Representation), yoğun vektör temsilleri veya diğer adıyla gömme vektörleri oluşturmak için tasarlanmış, denetimsiz bir öğrenme algoritmasıdır.
- Amacı, büyük bir metin külliyatındaki kelimelerin birlikte geçme örüntülerini analiz ederek kelimeler arasındaki anlamsal ilişkileri yakalamaktır.

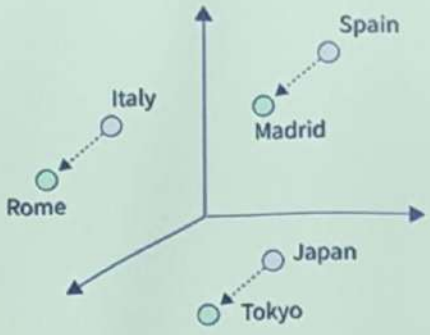

GloVe Adımları

1. Metni Ön İşleme Alın

- Öncelikle, metni üzerinde çalışabileceğimiz şekilde tek tek kelimelere ayırıyoruz
- *Giriş metni: " The man is ringing the bell"*
  Tokenleştirilmiş kelimeler: ['The', man', 'is', 'ringing', 'the', 'bell']

2. Kelime Dağarcığının Oluşturulması

- Tokenizasyon işleminden sonra, metindeki tüm benzersiz kelimelerin bir listesini oluşturuyoruz ve ardından her kelimenin kaç kez geçtiğini sayıyoruz.
- *Kelime sıklıklarıyla birlikte kelime dağarcığı:*
  {'The': 2, man': 1, 'is': 1, 'ringing': 1, 'the': 1, 'bell': 1}

GloVe Adımları

3. Birlikte Oluşma Matrisi

- Her kelimenin diğer kelimelerin yakınında ne sıklıkla göründüğünü sayarak bir birlikte geçme matrisi oluşturuyoruz.
- **Örnek:** Her kelimenin öncesinde ve sonrasında 2 kelime olacak şekilde 2'lik bir pencere boyutu seçtiğimizi varsayalım. Birlikte geçme matrisi şöyle bir şey olabilir:

	The	man	is	ringing	the	bell
The	0	1	1	1	1	0
man	1	0	1	1	0	0
is	1	1	0	1	1	0
ringing	1	1	1	0	1	1
the	1	0	1	1	0	1
bell	0	0	0	1	1	0

GloVe Adımları

- **6. Gömme Matrisi**
  - Eğitim tamamlandıktan sonra, model her kelimenin yoğun bir vektörle temsil edildiği bir gömme matrisi üretir. Bu vektörler, kelimeler arasındaki anlamsal ve sözdizimsel ilişkileri yakalayabilir.

Word	Vector
The	[0.3, 0.1, 0.5]
man	[0.2, 0.4, 0.3]
is	[0.6, 0.3, 0.4]
ringing	[0.1, 0.8, 0.7]
the	[0.3, 0.1, 0.5]
bell	[0.2, 0.3, 0.1]

GloVe Adımları

4. Nokta Çarpımı İşlemi

- Amaç, iki kelime vektörünün nokta çarpımının, kelimelerin bağlamda ne sıklıkla birlikte geçtiğini yansıtacak şekilde kelime vektörleri öğrenmektir. Bu, benzer bağlamlarda görünen kelimelerin benzer vektör gösterimlerine sahip olmasını sağlar.

5. Kelime Vektörlerinin Eğitimi

- Model, kelime vektörlerinin nokta çarpımı ile beklenen birlikte geçme olasılıkları (Noktasal Karşılıklı Bilgi, PMI olarak hesaplanır) arasındaki farkı en aza indirerek kelime vektörlerini optimize eder.

FastText

- Word2Vec'in gelişmiş versiyonudur.
- FastText kelimeyi *tek parça* olarak değil, alt parçalara (character n-gram) bölerek öğrenir.
- Word2Vec'te "apple" tek bir birimdir.
- FastText'te ise "apple" şu alt parçalara ayrılır (örnek 3–6 gram):

<ap, app, ppl, ple, le>
apple (kelimenin kendisi de eklenir)

- Model, kelimenin vektörünü bu alt parçaların vektörlerinin toplamı olarak öğrenir.

FastText

- FastText, özellikle morfolojik açıdan zengin diller için Word2Vec ve GloVe gibi geleneksel kelime gömme tekniklerine göre önemli bir avantaj sunmaktadır.
  - **Karakter Düzeyindeki Bilgilerin Kullanımı**
  - **Word2Vec Modelinin Genişletilmiş Hali**
  - **Sözlük Dışı Kelimelerin Ele Alınması**
  - **Morfolojik Açıdan Zengin Diller İçin Geliştirilmiş Vektör Gösterimleri**

FastText

- FastText gömme vektörleri, karakter düzeyindeki bilgileri kullanarak sağlam kelime temsilleri oluşturarak doğal dil işlemede devrim yaratıyor. Örneğin, karakter n-gram'larıyla **"basketbol" kelimesini ele alalım.**

```
"<ba, bas, ask, sket, ket, et, etb, tb, tb, bal, all, ll>" and "<basketball>".
```

Consider the word "running":

- **3-grams:** <ru, run, unn, nni, nin, ing, ng>
- **4-grams:** <run, runn, unni, nnin, ning, ing>
- **5-grams:** <runn, runni, unnin, nning, ning>

```
print("GloVe", glove_model.similarity("alice", "girl"))
print("CBOW : ", model1.wv.similarity("alice", "girl"))
print("Skip-Gram : ",  model2.wv.similarity("alice", "girl"))
print("FastText", ft.wv.similarity("alice", "girl"))
```

✓ 0.0s

```
GloVe 0.53167087
CBOW :  0.65594167
Skip-Gram :  0.69548005
FastText 0.7072453
```

```
print("GloVe", glove_model.similarity("king", "queen"))
print("CBOW : ", model1.wv.similarity("king", "queen"))
print("Skip-Gram : ", model2.wv.similarity("king", "queen"))
print("FastText", ft.wv.similarity("king", "queen"))
```

✓ 0.0s

```
GloVe 0.7507691
CBOW :  0.764935
Skip-Gram :  0.6978366
FastText 0.5384707
```

```
print("GloVe", glove_model.similarity("alice", "crime"))
print("CBOW : ", model1.wv.similarity("alice", "crime"))
print("Skip-Gram : ",  model2.wv.similarity("alice", "crime"))
print("FastText", ft.wv.similarity("alice", "crime"))
```

✓ 0.0s

```
GloVe 0.11961555
CBOW :  0.31014666
Skip-Gram :  0.49002665
FastText 0.6823713
```

```
print("GloVe", glove_model.similarity("detective", "crime"))
print("CBOW : ", model1.wv.similarity("detective", "crime"))
print("Skip-Gram : ",  model2.wv.similarity("detective", "crime"))
print("FastText", ft.wv.similarity("detective", "crime"))
```

✓ 0.0s

```
GloVe 0.5697438
CBOW :  0.80847126
Skip-Gram :  0.7342001
FastText 0.6704612
```

Genel Değerlendirme

Özellik	Word2Vec	GloVe	FastText
Model türü	Tahmin temelli kelime embedding	İstatistik temelli kelime embedding	Alt-kelime (subword) tabanlı embedding
Temel fikir	Bir kelimeyi bağlamından tahmin ederek öğrenir	Kelimelerin küresel birlikte-görülme istatistiklerini kullanır	Kelimeyi karakter n-gramlarına bölerek öğrenir
Bağlam türü	Yerel bağlam (pencere içi kelimeler)	Küresel bağlam (tüm korpus)	Yerel bağlam + kelime içi yapı
Kelime temsili	Kelime atomik bir birimdir	Kelime atomik bir birimdir	Kelime = karakter n-gramlarının toplamı
Alt modeller	CBOW, Skip-Gram	Alt modeli yok	CBOW, Skip-Gram
Metinde olmayan kelimeleri	Desteklemez	Desteklemez	Destekler
Nadir kelimeler	Zayıf temsil	Zayıf temsil	Güçlü temsil
Morfoloji (ekler, türevler)	Yakalayamaz	Yakalayamaz	Başarılı
Küçük veriyle öğrenme	Orta	Zayıf	Görece iyi
Hazır embedding kullanımı	Var	Çok yaygın	Var
Türkçe gibi eklemeli diller	Orta	Zayıf	Çok iyi
En uygun kullanım	Tek bir corpusa özgü anlam	Genel dil bilgisi	Yazım varyasyonu ve metinde olmayan kelime problemi durumları